

Priora – AI Agent za Inteligentnu Trijažu u Urgentnim Centrima

Opis agenta

Priora je AI agent razvijen za podršku medicinskom osoblju u urgentnim centrima prilikom određivanja prioriteta pregleda pacijenata. Sistem koristi mašinsko učenje kako bi na osnovu vitalnih znakova i glavne žalbe pacijenta predvidio ESI (Emergency Severity Index) nivo hitnosti od 1 do 5.¹ Cilj sistema nije zamjena medicinskog osoblja, već pružanje dodatne podrške u donošenju brzih i konzistentnih odluka tokom procesa trijaže.

U realnim uslovima rada urgentnih centara, medicinsko osoblje se svakodnevno suočava s velikim brojem pacijenata i visokim pritiskom donošenja odluka u veoma kratkom vremenu. Kašnjenje ili pogrešna procjena prioriteta može imati ozbiljne posljedice po zdravlje pacijenata. Priora smanjuje kognitivno opterećenje osoblja i omogućava bržu procjenu hitnosti slučaja, posebno tokom perioda preopterećenosti ili rada manje iskusnih trijažnih timova.

Agent koristi XGBoost model treniran nad skupom od približno 558.000 stvarnih zapisa iz urgentnih centara.² Tokom treniranja koriste se vitalni znakovi pacijenta, uključujući puls, krvni pritisak, temperaturu, saturaciju kisika, respiratornu frekvenciju i glavnu žalbu pacijenta. Podaci prolaze kroz pipeline za imputaciju nedostajućih vrijednosti, normalizaciju i kodiranje kategorijskih atributa prije samog treniranja modela.

Priora nakon unosa podataka trenutno vraća: predviđeni ESI nivo, procenat sigurnosti modela, kompletnu distribuciju vjerovatnoće za svih pet ESI klasa, kliničku preporuku za dalje postupanje, printabilni trijažni izvještaj za fizički karton pacijenta.

Frontend sistema razvijen je korištenjem React i TypeScript tehnologija uz moderan responzivan interfejs prilagođen radu u urgentnim centrima. Backend je implementiran korištenjem FastAPI frameworka, dok je model implementiran putem biblioteka Scikit-learn i XGBoost.³

Sistem je dizajniran kao alat za podršku odlučivanju i konačna medicinska odluka uvijek ostaje u nadležnosti zdravstvenog radnika. Priora predstavlja primjer praktične primjene vještačke inteligencije u zdravstvu s ciljem povećanja efikasnosti, standardizacije i sigurnosti procesa trijaže.⁴

¹ Gilboy, N., Tanabe, P., Travers, D., & Rosenau, A. M. (2012). Emergency Severity Index (ESI): A Triage Tool for Emergency Department Care, Version 4. Agency for Healthcare Research and Quality.

² Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining.

³ Pedregosa, F., Varoquaux, G., Gramfort, A., et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825–2830.

⁴ Raita, Y., Goto, T., Faridi, M. K., Brown, D. F. M., Camargo, C. A., & Hasegawa, K. (2019). Emergency Department Triage Prediction of Clinical Outcomes Using Machine Learning Models. Critical Care, 23(1), 64.